Сравнение систем синтеза речи (TTS)

Проектная работа «Текст в голос», спринт 1



Выполнили: Соломахин Е. И., Мажаров А. В., Ишутов М. С.

Руководитель: Плотникова Н. В.

Предприятие-заказчик: ЧКПЗ (Челябинский кузнечно-прессовый завод)

Цель и задачи

ЦЕЛЬ

Рассмотреть архитектуры систем синтеза речи, определить области их применения на предприятии и сравнить решения (Yandex SpeechKit, ElevenLabs, openbmb/VoxCPM2).

Задачи

1. Изучить структуру систем синтеза речи и эволюцию подходов.
2. Рассмотреть ключевые архитектуры: от Tacotron до гибридных и End-to-End моделей.
3. Описать метрики качества и нерешённые проблемы.
4. Определить сценарии применения синтеза речи на предприятии (ЧКПЗ).
5. Сравнить системы по преимуществам, недостаткам и стоимости.

Конвейер системы синтеза речи - Этап 1

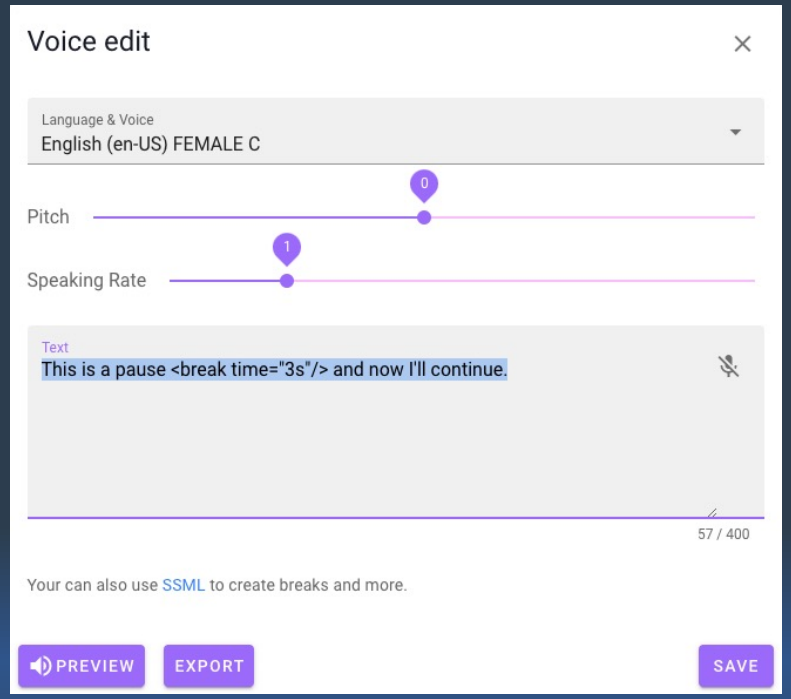
1 · Обработка текста (NLP) - 2 · Акустическая модель - 3 · Вокодер

Текст - Обработка естественного языка (NLP)

Нормализация текста под речь:

- Перевод графем в фонемы (например: «4» - «четыре», «молоко» - «малако»)
- Автоматическая расстановка ударений
- Определение границ предложений и пауз
- Анализ эмоций и интонации

ПРИМЕР С SSML-РАЗМЕТКОЙ



Конвейер системы синтеза речи - Этап 2

1 · Обработка текста (NLP) - **2 · Акустическая модель** - 3 · Вокодер

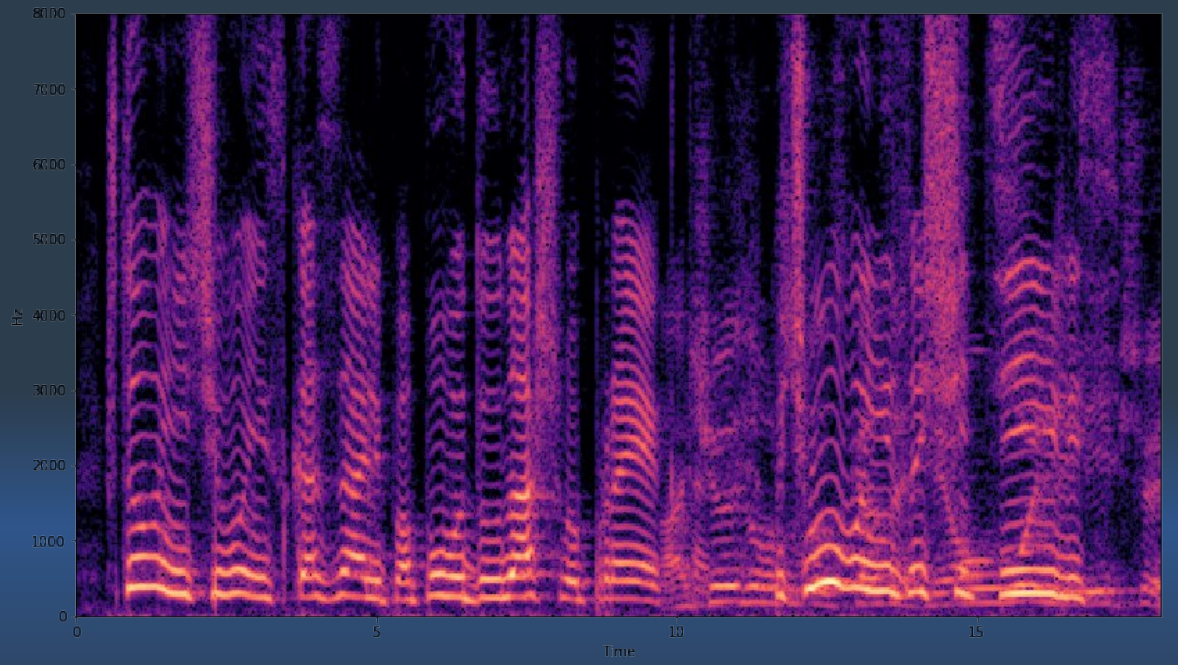
Фонемы - Акустическая модель - Мел-спектрограмма

Акустическая модель:

- Принимает на вход последовательность фонемных векторов.
- Отдаёт мел-спектрограмму (визуальное представление частот, воспринимаемых человеческим ухом).
- Определяет громкость и частотные характеристики будущего звука.

Проблема классических моделей: спектрограмма отображает данные окнами, что может терять микродетали звука.

Мел-спектрограмма: время × частота



Конвейер системы синтеза речи - Этап 3

1 · Обработка текста (NLP) - 2 · Акустическая модель - **3 · Вокодер**

Мел-спектрограмма - Вокодер - Звуковая волна

Вокодер (волновой кодировщик):

- Восстанавливает каждое отдельное колебание звуковой волны.
- Превращает спектрограмму в финальный аудиофайл (WAV/MP3).



Дополнительно: клонирование голоса

Анализ примера голоса - **Классификатор** - **Промежуточный вектор (тембр)**

Позволяет синтезировать речь, имитирующую конкретного человека.

Эволюция подходов к синтезу речи

Поколение	Идея	Сильные стороны	Слабые стороны
Склейка (конкатенативный)	Склейка заранее записанных юнитов	Естественность тембра, высокая скорость	Монотонность, артефакты на стыках фраз
Параметрический (формантный)	Предсказание параметров + простой вокодер	Мало данных для обучения	Низкое качество, «роботизированный» звук
Нейросетевой	Tacotron 2 + WaveNet (механизм внимания)	Высокое качество и естественность	Медленная генерация в реальном времени
Диффузионный	Grad-TTS: постепенное удаление шума из спектрограммы	Отличный баланс качества и стабильности	Итеративность процесса (требует ресурсов)
End-to-End	VITS / F5-TTS: объединение всех этапов в одну сеть	Высокая скорость, отличное клонирование голоса	Чёрный ящик

Сравнение акустических моделей (метрики)

Модель	MOS (качество, из 5)	RTF (скорость)
Grad-TTS-1000	4.44	3.663
Grad-TTS-10	4.38	0.033
Tacotron 2	4.32	0.075
Glow-TTS	4.11	0.008
FastSpeech	3.68	0.004
Речь человека	**4.53**	**1.0**

MOS

Mean Opinion Score - средняя субъективная оценка естественности от людей.

RTF

Real Time Factor = время работы / длительность результата (чем меньше, тем быстрее).

Grad-TTS-1000 лучше всех по качеству (4.44), но RTF 3.663 - медленнее реального времени. Grad-TTS-10 сохраняет качество 4.38 при RTF 0.033.

Применение синтеза речи на предприятии ЧКПЗ

1

Охрана труда и инструктажи

Автоматическое озвучивание инструкций, мгновенное обновление без записи диктора.

2

Оповещение в цехах

Аварийные объявления, смена режима работы пресса, эвакуация (голос работает там, где визуальный экран бесполезен).

3

Голосовые подсказки операторам

Руки заняты заготовкой или штампом, читать техкарту нельзя.

4

Обучение и адаптация новичков

Курсы, регламенты и ГОСТы в доступном аудиоформате.

5

Диспетчеризация и логистика

Автоматические объявления на складах, в отгрузке, на проходной.

Сравнение систем синтеза речи

Сервис	Преимущества	Недостатки	Стоимость
Yandex SpeechKit	Дешёвый, быстрый, соответствие 152-ФЗ	Требует интернет. Нет SSML, металический звук.	~150-300 ₽ за 1 млн символов
ElevenLabs	Лучшее в индустрии клонирование голоса, мультиязычность, естественность	Сложности с оплатой из РФ, данные хранятся за рубежом	От $5/мес (30 000 символов)
openbmb/VoxCPM 2	Открытая модель, работает локально (On-premise), клонирование голоса	Требует GPU (8+ ГБ памяти), нужна своя инфраструктура	Бесплатно (свой сервер)

Вывод: Yandex подходит для офисных задач, VoxCPM2 - для безопасного локального развёртывания в цехах, ElevenLabs - для создания уникального корпоративного голоса (при решении вопросов оплаты).

Заключение

Ключевые выводы

1. TTS эволюционировала от склейки записей к нейросетям, чьё качество (MOS 4.4-4.5) практически неотличимо от человека.

2. Схема «NLP - акустическая модель - вокодер» остаётся основой, но тренд смещается в сторону End-to-End моделей.

3. Для предприятия синтез речи экономически выгоден в инструктажах, оповещениях и обучении, устраняя необходимость в постоянных услугах диктора.

4

Рекомендация для ЧКПЗ

Гибридный подход.

Yandex SpeechKit для облачных/офисных задач + локальное развёртывание open-source модели (VoxCPM2/Silero) для закрытых цеховых контуров.

Постановка задачи на проект. Backend

Цель: разработать надёжное REST API, связывающее пользовательский интерфейс и TTS-движок.

АРХИТЕКТУРА: ТРЁХЗВЕННАЯ

Клиент – **Backend** – **TTS API / Локальная модель**

КЛЮЧЕВЫЕ ЭНДПОИНТЫ (API-КОНТРАКТ)

Метод	Эндпоинт	Назначение
GET	`/api/v1/voices`	Получение списка доступных голосов
POST	`/api/v1/voices`	Регистрация нового голоса (приём аудиосэмпла для клонирования)
POST	`/api/v1/synthesize`	Приём текста и voice_id, возврат ссылки на готовый аудиофайл
GET	`/api/v1/history`	Выгрузка журнала генераций для конкретного пользователя

Хранение: метаданные в PostgreSQL, аудиофайлы в локальной файловой системе или S3-хранилище.

Постановка задачи на проект. Frontend

Цель: создать интуитивный веб-интерфейс (Dashboard) для диспетчеров и мастеров ЧКПЗ.

КЛЮЧЕВЫЕ ЭКРАНЫ (MVP)

1

Библиотека голосов

Управление шаблонами: выбор из готовых или загрузка 30-секундного сэмпла.

2

Студия генерации

Текстовое поле для инструктажа, выбор голоса, настройка скорости/пауз (SSML), кнопка «Сгенерировать» и встроенный аудиоплеер.

3

История операций

Таблица с датой, текстом, использованным голосом и кнопкой повторного скачивания.

Стек: HTML/CSS/JS (или React), адаптивная вёрстка для работы с планшетов в цеху.

Постановка задачи на проект. Модель

Цель: обеспечить качественную и безопасную генерацию речи с учётом специфики терминологии ЧКПЗ.

СТРАТЕГИЯ РЕАЛИЗАЦИИ (3 УРОВНЯ)

1	**MVP (быстрый старт)**	Использование облачного API (Yandex SpeechKit) для проверки гипотезы и офисных задач.
2	**Целевой (Fine-tuning)**	Дообучение открытой модели (например, speechT5) на небольшом датасете (30–60 минут) с реальными цеховыми инструкциями.
3	**Перспектива (R&D)**	Создание и разметка большего датасета со множеством дикторов. Создание свой модели с отладкой каждого участка конвейера.

Список источников

1. Обзор технологий синтеза речи // Хабр, Т-Банк. 2019.
2. Hugging Face Audio Course. Unit 3: Refresher on transformer models, CTC architectures, Seq2Seq architectures.
3. Синтез речи // ИТМО, Викиконспекты.
4. Liu A. H. et al. Voxtral TTS // arXiv:2603.25551. 2026.
5. Popov V. et al. Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech // ICML 2021.