Проектная работа «Текст в голос» · Спринт 1

Сравнение систем синтеза речи (TTS)

Соломахин Е. И., Мажаров А. В., Ишутов М. С. · группа 201

Руководитель: Плотникова Н. В. · ЮУрГУ, Центр «Цифровой Урал» · Челябинск, 2026

Цель и задачи

Цель

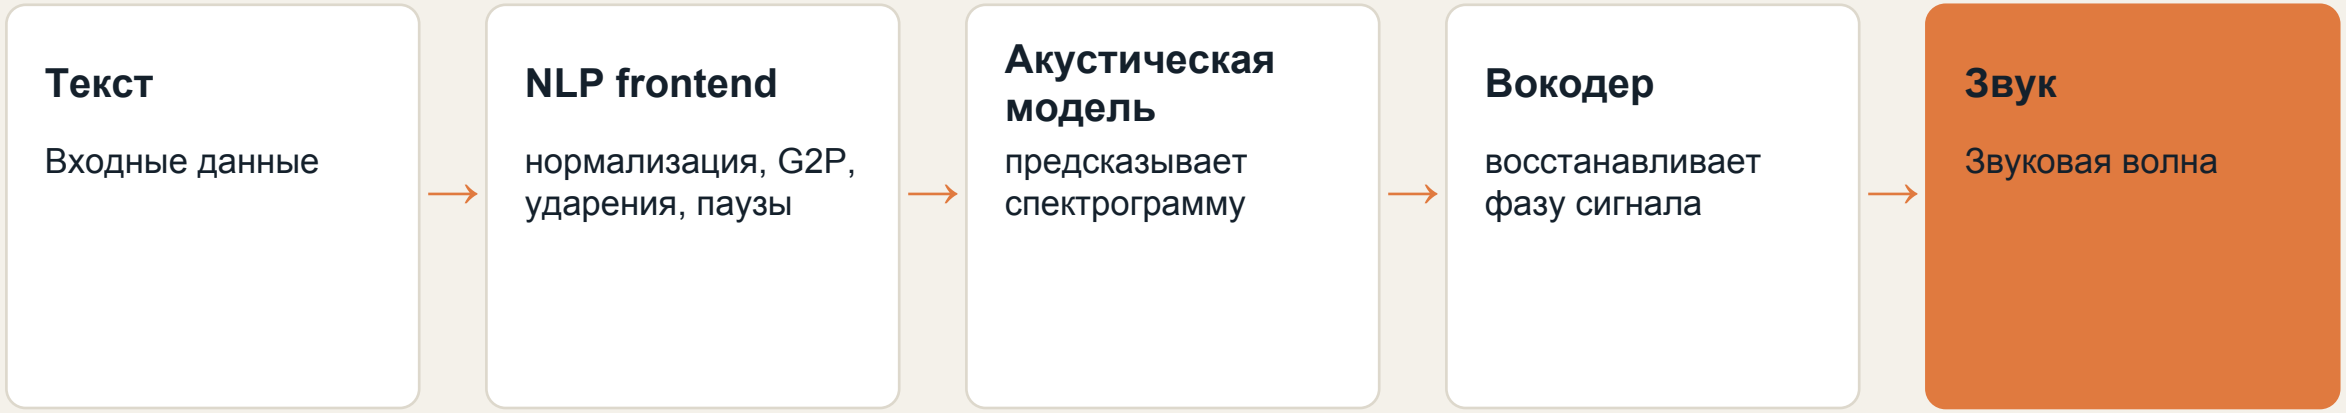
Рассмотреть архитектуры систем синтеза речи, определить области их применения на предприятии и сравнить ElevenLabs, Yandex SpeechKit и openbmb/VoxCPM2

Задачи

- Структура систем и эволюция подходов
- Ключевые архитектуры: от Tacotron до гибридов
- Метрики качества и нерешённые проблемы
- Сценарии применения на предприятии
- Сравнение систем по плюсам, минусам и цене

Актуальность: запись диктора на каждое изменение текста обходится дорого

Структура системы синтеза речи



Спектрограмма хранит амплитуды, но не фазу, поэтому нужен отдельный вокодер. End-to-end модели постепенно размывают эти границы.

Источники: [1, 2, 3]

Эволюция подходов

Поколение	Идея	Сильные стороны	Слабые стороны
Unit selection	Склейка записанных юнитов	Естественность, скорость	Монотонность, артефакты
Параметрический	Предсказание параметров + вокодер	Мало данных	Низкое качество
Нейросетевой	Tacotron 2 + WaveNet	MOS около 4,5	Медленная генерация
Диффузионный	Grad-TTS: шум → спектрограмма	Баланс качества и скорости	Итеративность
Токенный гибрид	Voxtral TTS: токены + flow matching	Клонирование голоса, стриминг	Большая модель, лицензия NC

Источники: [1, 3, 4, 5]

Ключевые архитектуры

4,52

Tacotron 2

MOS против 4,58 у записанной речи. Текст подаётся на вход, WaveNet-вокодер даёт звук

4,38

Grad-TTS-10

Диффузионная модель на 10 шагах: вдвое быстрее Tacotron 2 при сопоставимом качестве

68,4%

Voxtral TTS

Предпочтений против ElevenLabs Flash v2.5; голос клонируется по 3 секундам, 9 языков

Источники: [3, 4, 5]. MOS: оценка естественности по шкале от 1 до 5

Применение на предприятии

Инструктажи

Охрана труда без записи диктора

Оповещение

Аварийные объявления в шумных цехах

Подсказки

Шаги и предупреждения операторам

Обучение

Курсы и регламенты для новичков

Диспетчеризация

Склад, отгрузка, проходная

Новости

Приказы в аудиоформате

Доступность

Помощь людям с нарушением зрения и иностранным рабочим

Требования

Быстрая генерация, обновление текстов без диктора, несколько языков

Сравнение систем синтеза речи

Сервис	Преимущество	Недостаток	Стоимость
ElevenLabs	Высокое качество, много голосов, SSML	Невозможна оплата	5 копеек за символ
Yandex SpeechKit	Дёшево, реальное время	Металлические шумы, нет SSML	0,1 копейки за символ
VoxCPM2	Открытая модель, качество, SSML	Не менее 8 ГБ памяти	Бесплатно, свой сервер

Вывод: Yandex SpeechKit подходит для быстрых оповещений, VoxCPM2 для качества и управления произношением. ElevenLabs недоступен из-за оплаты.