МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
ЮЖНО-УРАЛЬСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

Центр подготовки топ-специалистов в сфере информационных технологий «Цифровой Урал»

Сравнение систем синтеза речи (TTS)

Проектная работа «Текст в голос», спринт 1

Выполнили: студенты группы 201
Соломахин Е. И., Мажаров А. В., Ишутов М. С.
Руководитель: Плотникова Н. В.

Челябинск 2026

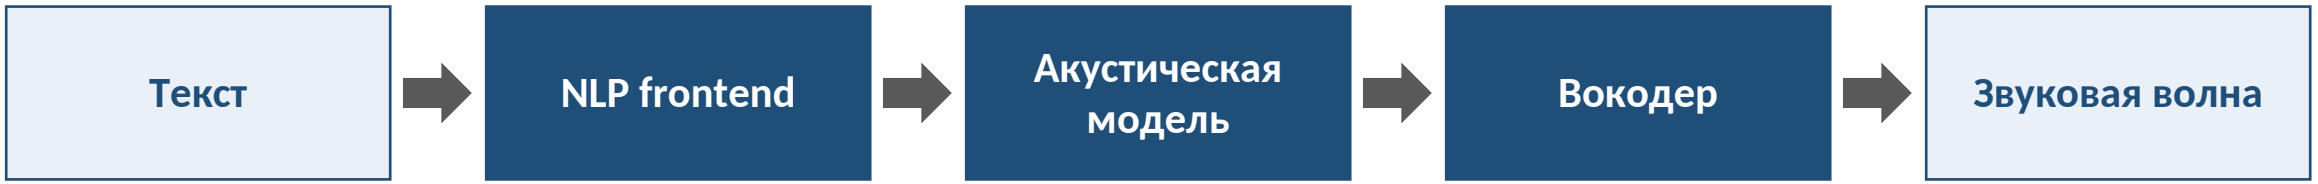
Цель и задачи

Цель: рассмотреть архитектуры систем синтеза речи, определить области их применения на предприятии и сравнить ElevenLabs, Yandex SpeechKit и openbmb/VoxCPM2.

Задачи:

- изучить структуру систем синтеза речи и эволюцию подходов
- рассмотреть ключевые архитектуры, от Tacotron до гибридных моделей
- описать метрики качества и нерешённые проблемы
- определить сценарии применения синтеза речи на предприятии
- сравнить системы по преимуществам, недостаткам и стоимости

Структура системы синтеза речи



- NLP frontend: нормализация текста, перевод графем в фонемы (G2P), ударения, паузы
- акустическая модель предсказывает мел-спектрограмму, длительности фонем и частоту основного тона
- вокодер переводит признаки в звуковую волну и восстанавливает фазу, которой нет в спектрограмме
- современные end-to-end модели постепенно объединяют эти этапы

Эволюция подходов к синтезу речи

Поколение	Идея	Сильные стороны	Слабые стороны
Unit selection	Склейка записанных юнитов	Естественность, скорость	Монотонность, артефакты
Параметрический	Предсказание параметров и вокодер	Мало данных	Низкое качество
Нейросетевой	Tacotron 2 и WaveNet	MOS около 4,5	Медленная генерация
Диффузионный	Grad-TTS: шум в спектрограмму	Баланс качества и скорости	Итеративность
Токенный гибрид	Voxtral TTS: токены и flow matching	Клонирование голоса, стриминг	Большая модель, лицензия NC

Ключевые архитектуры

- Tacotron 2: MOS 4,52 против 4,58 у записанной речи
- Grad-TTS: диффузионная модель, число шагов выбирается после обучения; с 10 шагами примерно вдвое быстрее Tacotron 2
- Voxtral TTS: клонирование голоса по 3 секундам, 9 языков; 68,4 % предпочтений против ElevenLabs Flash v2.5

Сравнение акустических моделей (MOS, RTF на GPU)

Модель	MOS	RTF
Grad-TTS-1000	4,44	3,663
Grad-TTS-10	4,38	0,033
Grad-TTS-4	3,96	0,012
Tacotron 2	4,32	0,075
Glow-TTS	4,11	0,008
FastSpeech	3,68	0,004
Речь человека	4,53	—

Применение синтеза речи на предприятии

- охрана труда и инструктажи
- оповещение в цехах
- голосовые подсказки операторам
- обучение и адаптация новичков
- диспетчеризация и логистика
- внутренние новости и приказы
- доступность для сотрудников с нарушением зрения и иностранных рабочих

Требования к системе: быстрая генерация, частое обновление текстов без диктора, поддержка нескольких языков.

Сравнение систем синтеза речи

Сервис	Преимущество	Недостаток	Стоимость
ElevenLabs	Высокое качество, много голосов, SSML	Невозможна оплата	5 копеек за символ
Yandex SpeechKit	Низкая цена, реальное время	Металлические шумы, нет SSML	0,1 копейки за символ
openbmb/VoxCPM2	Открытая модель, качество, SSML	Нужно не менее 8 ГБ памяти	Бесплатно, свой сервер

Вывод: Yandex SpeechKit подходит для быстрых оповещений, VoxCPM2 для качества и управления произношением. ElevenLabs недоступен из-за оплаты.

Заключение

- TTS развивалась от склейки записей через статистические модели к нейросетям, по MOS близким к человеку
- схема «frontend, акустическая модель, вокодер» остаётся основой, но появляются end-to-end модели и системы на аудиотокенах
- оценка качества остаётся слабым местом: без людей надёжно проверить естественность нельзя
- для предприятия синтез речи применим в инструктажах, оповещениях, обучении и других задачах
- Yandex SpeechKit выигрывает в цене и скорости, VoxCPM2 даёт качество и SSML при наличии ресурсов

Список источников

1. Обзор технологий синтеза речи // Хабр, Т-Банк. 2019.
2. Hugging Face Audio Course. Unit 3: Refresher on transformer models, CTC architectures, Seq2Seq architectures.
3. Синтез речи // ИТМО, Викиконспекты.
4. Liu A. H. et al. Voxtral TTS // arXiv:2603.25551. 2026.
5. Popov V. et al. Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech // ICML 2021.