Сравнение систем синтеза речи (TTS)

Проектная работа «Текст в голос», спринт 1

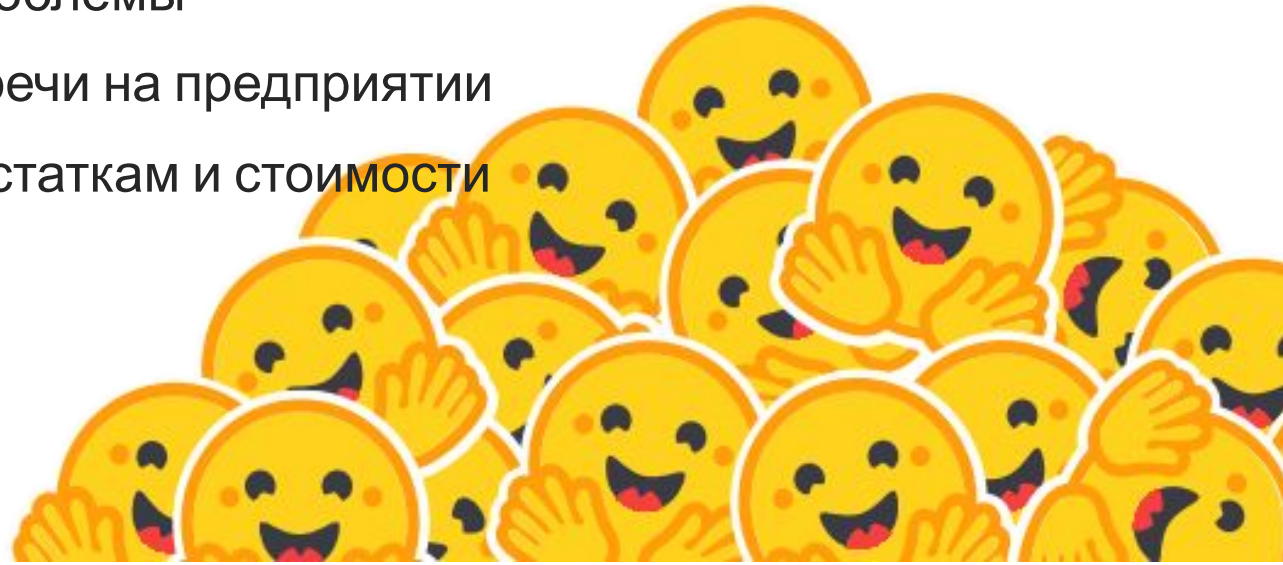
Выполнили
Соломахин Е. И., Мажаров А. В., Ишутов М. С.
Руководитель: Плотникова Н. В.

Цель и задачи

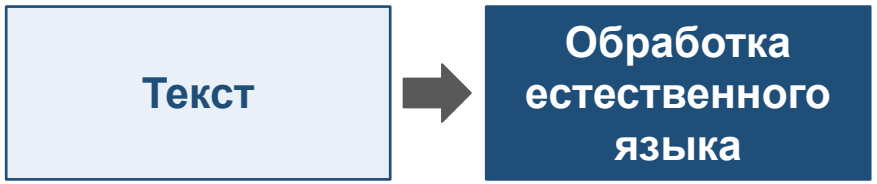
Цель: рассмотреть архитектуры систем синтеза речи, определить области их применения на предприятии и сравнить , , IIElevenLabs и oper /VoxCPM2.

Задачи:

- изучить структуру систем синтеза речи и эволюцию подходов
- рассмотреть ключевые архитектуры, от Tacotron до гибридных моделей
- описать метрики качества и нерешенные проблемы
- определить сценарии применения синтеза речи на предприятии
- сравнить системы по преимуществам, недостаткам и стоимости



Конвейер системы синтеза речи

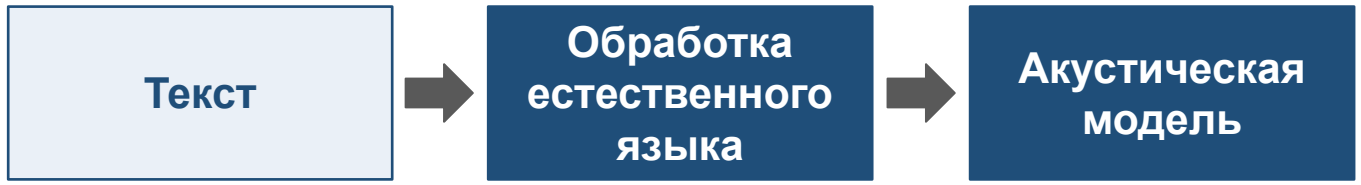


Нормализация текста под речь:

- перевод графем в фонемы (4 -> четыре, молоко -> малако, 😮 -> охо)
- ударения
- паузы
- эмоции/интонации

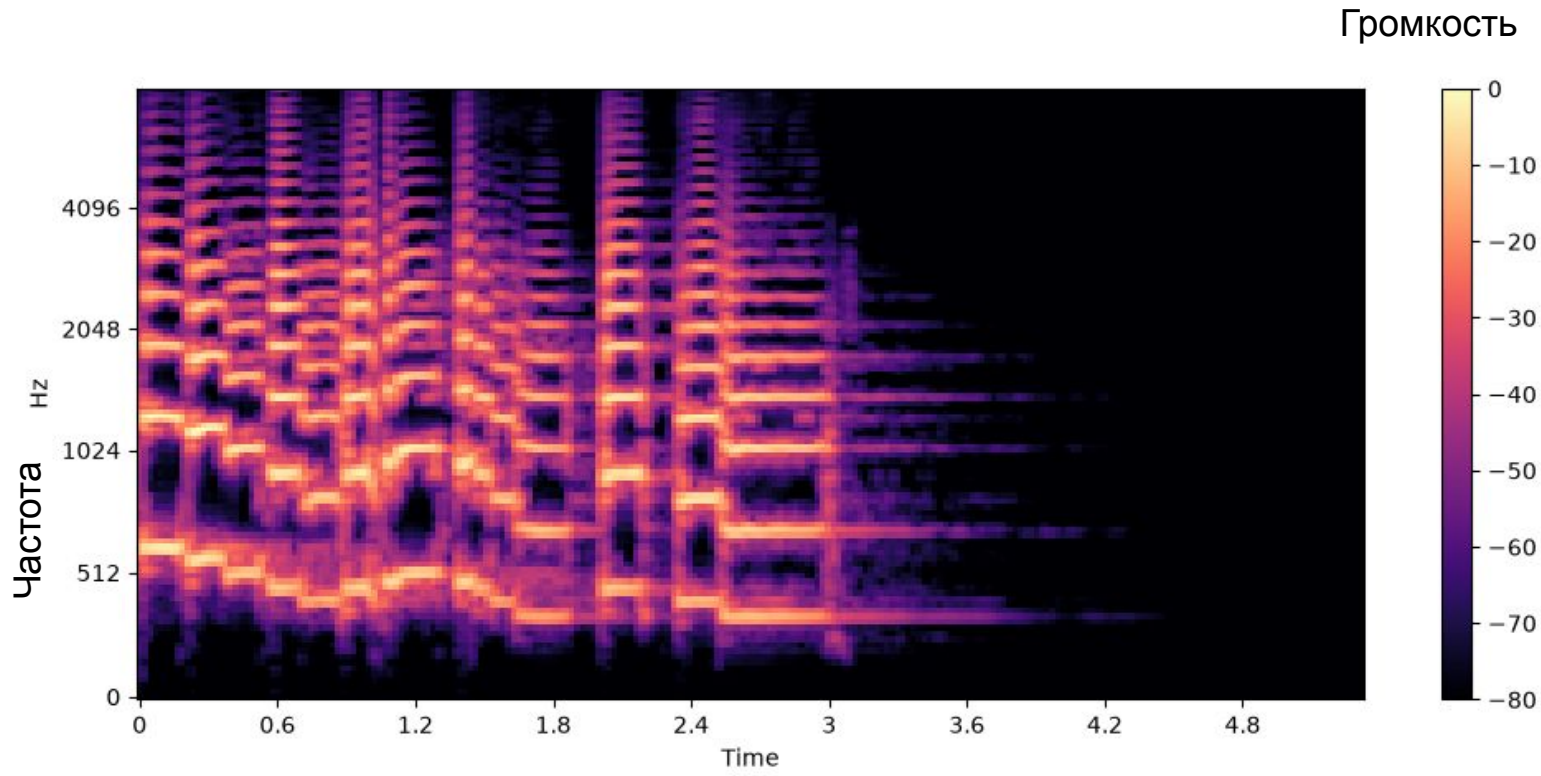
<Радость>Ура[0,5 секунд] мы победили этат замÓк</Радость>

Конвейер системы синтеза речи

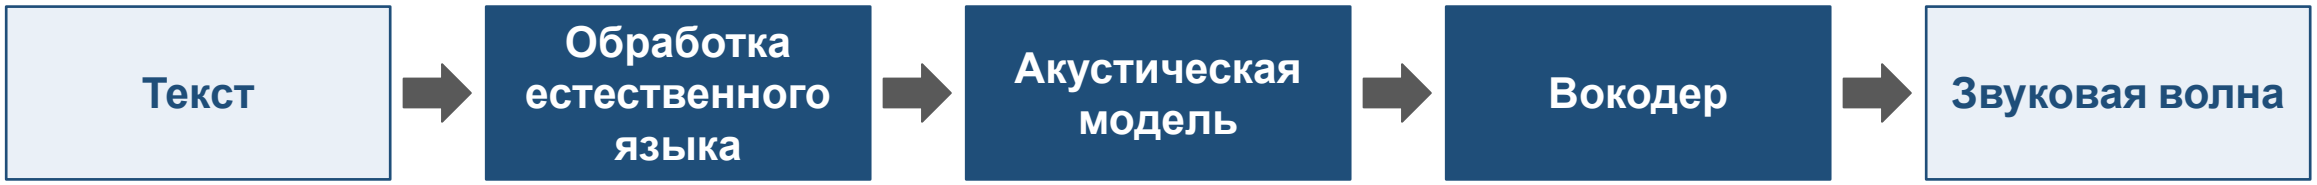


Акустическая модель:

- Принимает на вход последовательность векторов
- Отдаёт мел-спектрограмму.
  Какие частоты/детали слышны человеку.



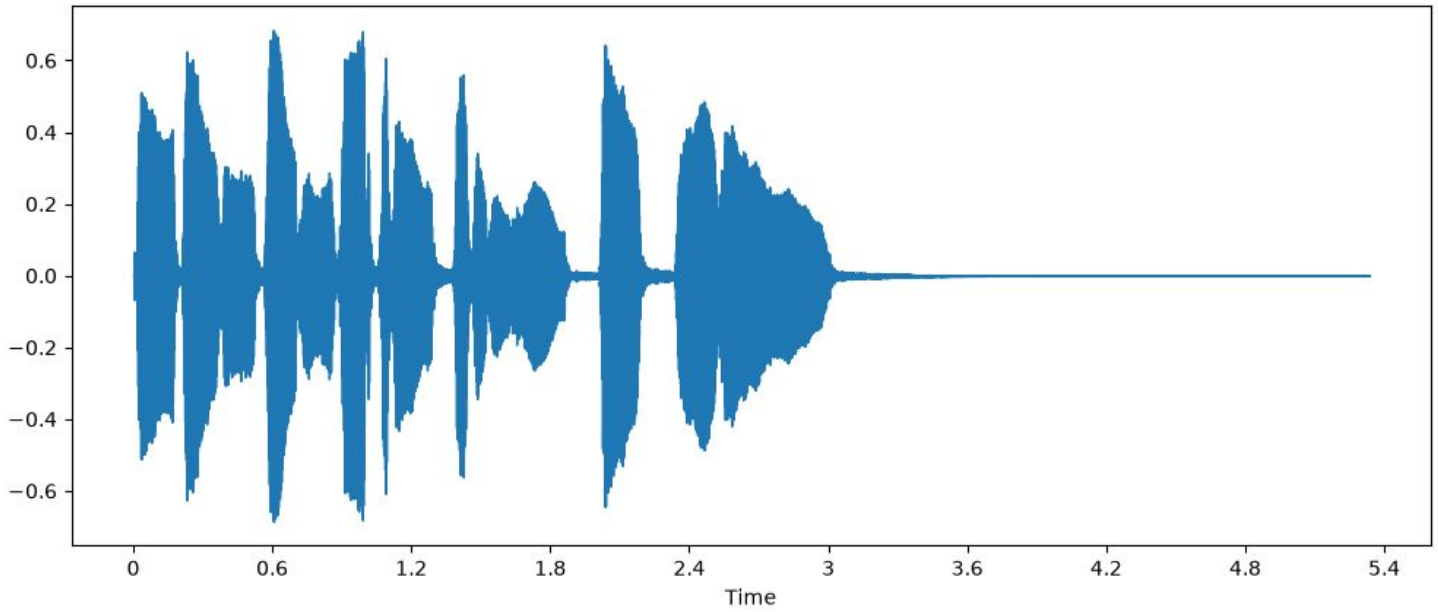
Конвейер системы синтеза речи



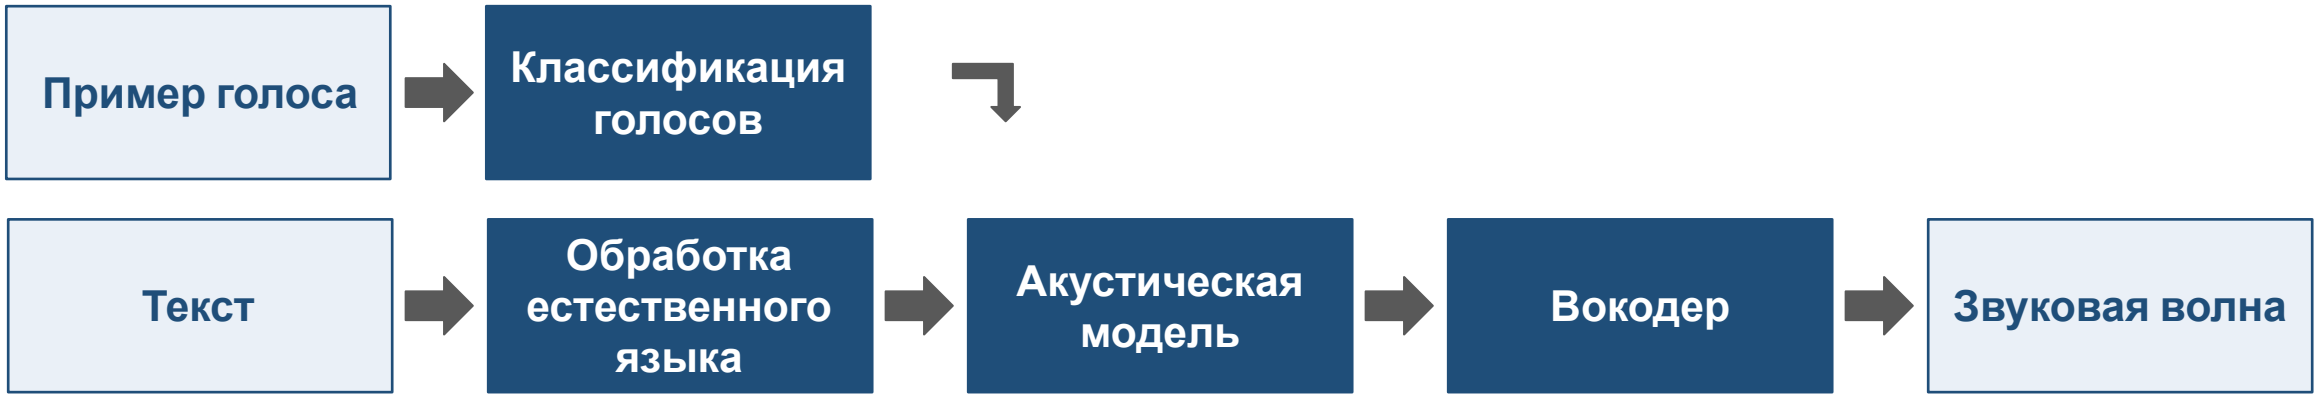
Проблема: Спектрограмма отображает некоторые данные окнами

Волновой кодировщик:

Восстанавливает каждое отдельное колебание.

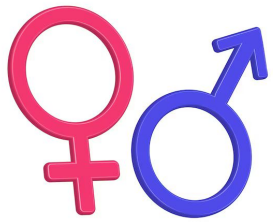


Конвейер системы синтеза речи

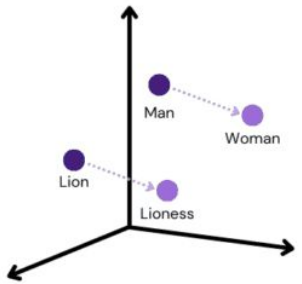


Классификатор:

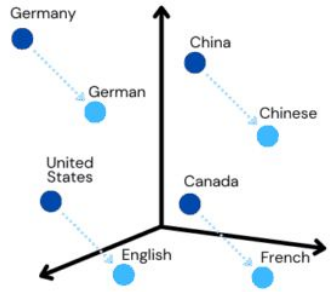
Отдаёт промежуточный вектор, который характеризует голос



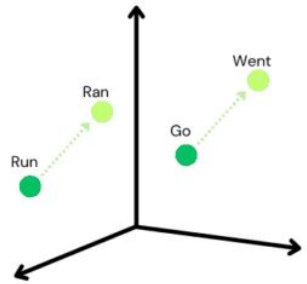




Male - Female



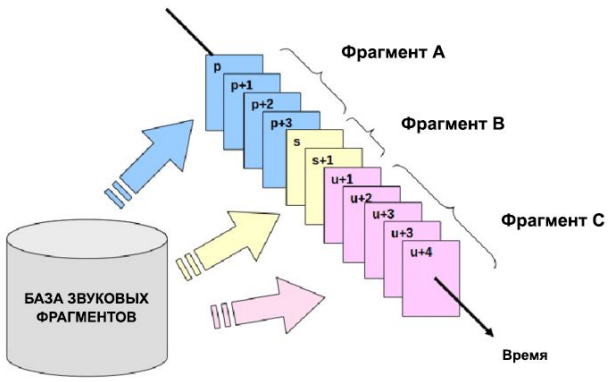
Country - Language



Verb Tense

Эволюция подходов к синтезу речи

Поколение	Идея	Сильные стороны	Слабые стороны
Склейка	Склейка записанных юнитов	Естественность, скорость	Монотонность, артефакты
Параметрический	Предсказание параметров и вокодер	Мало данных	Низкое качество
Нейросетевой	Tacotron 2 и WaveNet – Внимание и причинная свёртка	Высокое качество	Медленная генерация
Диффузионный	Grad-TTS: шум в спектрограмму	Баланс качества и скорости	Итеративность
Токенный гибрид	Voxtral TTS: токены и подвод потока	Клонирование голоса, стриминг	Большая модель





Сравнение акустических моделей

Диффузия

Прямые нейросетевые

Модель	MOS	RTF
Grad-TTS-1000	4,44	3,663
Grad-TTS-10	4,38	0,033
Grad-TTS-4	3,96	0,012
Tacotron 2	4,32	0,075
Glow-TTS	4,11	0,008
FastSpeech	3,68	0,004
Речь человека	4,53	1

**MOS - средняя субъективная оценка от людей

**RTF = время работы/время результата

Применение синтеза речи на предприятии

- Инструктажи и обучение
- оповещение в цехах и диспетчерезация
- голосовые подсказки операторам
- обучение и адаптация новичков
- перевод речи







Требования к системе: быстрая генерация, частое обновление текстов без диктора, поддержка нескольких языков.

Сравнение систем синтеза речи

Сервис	Преимущество	Недостаток	Стоимость
ElevenLabs	Высокое качество, много голосов, SSML	Невозможна оплата	5 копеек за символ
Yandex SpeechKit	Низкая цена, реальное время	Металлические шумы, нет SSML	0,1 копейки за символ
openbmb/VoxCPM2	Открытая модель, качество, SSML	Нужно не менее 8 ГБ памяти	Бесплатно, свой сервер

Вывод: Yandex SpeechKit подходит для быстрых оповещений, VoxCPM2 для качества и управления произношением. ElevenLabs недоступен из-за оплаты.

Заключение

- TTS развивалась от склейки записей через статистические модели к нейросетям, по MOS близким к человеку
- схема «frontend, акустическая модель, вокодер» остается основой, но появляются end-to-end модели и системы на аудио токенах
- оценка качества остаётся слабым местом: без людей надёжно проверить естественность нельзя
- для предприятия синтез речи применим в инструктажах, оповещениях, обучении и других задачах
- Yandex SpeechKit выигрывает в цене и скорости, VoxCPM2 даёт качество и SSML при наличии ресурсов

Постановка задачи на проект.Backend

Постановка задачи на проект.Frontend

Постановка задачи на проект.Модель

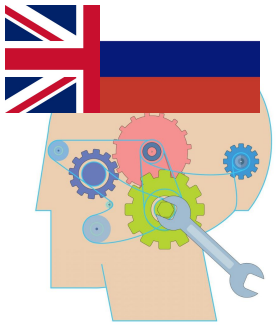
Написание обёртки для существующих моделей с huggingface или облачных вариантов.



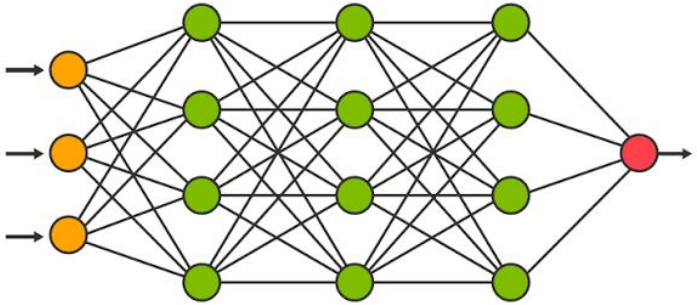
Составление единого датасета из разных источников.

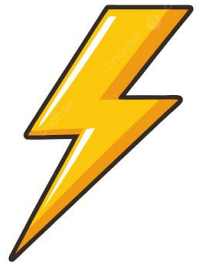


Дообучение фундаментальной модели для повышения качества русского языка.



Обучение своей модели. Стремление к реальному времени.





Список источников

1. Обзор технологий синтеза речи // Хабр, Т-Банк. 2019.
2. Hugging Face Audio Course. Unit 3: Refresher on transformer models, CTC architectures, Seq2Seq architectures.
3. Синтез речи // ИТМО, Викиконспекты.
4. Liu A. H. et al. Voxtral TTS // arXiv:2603.25551. 2026.
5. Popov V. et al. Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech // ICML 2021.